



UNIVERSIDADE FEDERAL DA BAHIA
ESCOLA POLITÉCNICA
DEPARTAMENTO DE ENGENHARIA ELÉTRICA
E DE COMPUTAÇÃO
ENGG54 – LABORATÓRIO INTEGRADO III-A



Amanda Bastos de Melo Correia
Júlia Teixeira Gonçalves
Maria Clara Andrade Magalhães Paternostro D'Oliveira

Diagnóstico Acústico de Falhas em Motores Rotativos com Processamento Digital de Sinais Embarcado

Sumário

1	Objetivos	2
1.1	Objetivo Geral	2
1.2	Objetivos Específicos	2
2	Justificativa	2
3	Metodologia	5
3.1	Solução Proposta	5
3.2	Avaliação da Solução	7
4	Resultados Esperados	7
5	Infraestrutura Necessária	8
6	Metas Físicas	9
7	Cronograma de Atividades	10
8	Orçamento	11
9	Riscos Potenciais	11
10	Metodologia de Gerenciamento	12
11	Bibliografia	12

1 Objetivos

1.1 Objetivo Geral

Desenvolver e demonstrar, em hardware embarcado, um sistema capaz de distinguir a condição de operação de motores rotativos, a priori de forma binária: operação normal ou operação em falha, a partir de sinais de áudio pré-gravados, buscando o melhor desempenho de classificação possível sobre o conjunto de teste do dataset utilizado, com toda a cadeia de extração de características e inferência executando embarcada. A discriminação do tipo específico de falha constitui objetivo estendido, a ser perseguido após a validação da cadeia embarcada.

1.2 Objetivos Específicos

- a) Selecionar e preparar um subconjunto de dados de áudio de motores rotativos, público e rotulado, adequado ao armazenamento em memória embarcada;
- b) Implementar em Python um pipeline de pré-processamento (reamostragem, normalização, janelamento) e extração de características (MFCC) sobre esse conjunto de dados;
- c) Treinar e validar, em software, um classificador leve capaz de distinguir operação normal de operação em falha, com implementação parametrizada pelo número de classes, de modo a permitir a extensão posterior à identificação do tipo de falha;
- d) Portar a cadeia de processamento digital de sinais e o classificador treinado para o hardware embarcado, armazenando os sinais de teste e os parâmetros do modelo em memória não volátil;
- e) Validar o sistema embarcado com os cliques de teste do dataset, com sinalização local por LEDs e interface de diagnóstico detalhado em computador, alimentada por comunicação serial.

2 Justificativa

Motores rotativos são elementos centrais em praticamente toda a infraestrutura industrial, e sua falha inesperada gera custos de manutenção elevados, paradas de produção e até, em alguns casos, riscos à segurança. Historicamente, o diagnóstico de falhas nesses equipamentos é feito por meio de análise de vibração, corrente elétrica ou termografia (técnicas eficazes, porém dependentes de sensores de contato, instalação cuidadosa e, frequentemente, de custo elevado). A análise acústica surge como alternativa não invasiva e

de baixo custo: motores em falha (por exemplo, rolamentos com defeito nas pistas interna ou externa) alteram de forma perceptível o som que emitem durante a operação, o que permite, em princípio, diagnosticar seu estado sem contato físico.

O diagnóstico de falhas em rolamentos é um dos problemas mais estudados em manutenção preditiva industrial, pois rolamentos defeituosos respondem por parcela significativa das falhas em máquinas rotativas. Métodos tradicionais de diagnóstico acústico dependem de microfones e processamento em computadores de propósito geral; poucos trabalhos exploram a viabilidade de executar toda a cadeia (da extração de características até a classificação) diretamente em um microcontrolador ou DSP de baixo custo, como exige a proposta desta disciplina. É esse recorte de viabilidade embarcada, com recursos de memória e processamento limitados que define o problema de estudo deste projeto.

A literatura consultada para embasar a proposta cobre quatro frentes complementares.

Jung et al. (2023) disponibilizam um dos poucos conjuntos de dados públicos que registram, simultaneamente, vibração, *áudio*, temperatura e corrente de um motor de indução trifásico real sob falhas controladas de rolamento (pistas interna e externa, em diferentes severidades), desalinhamento de eixo e desbalanceamento de rotor. O subconjunto acústico, coletado com microfone a 51,2 kHz sob carga nula, é o único dos quatro trabalhos com som real de máquina rotativa em falha documentado e rotulado, e é a base de dados escolhida para este projeto (justificativa detalhada na Seção 3).

Tian et al. (2023) propõem a Wavelet-SANet, uma rede que decompõe o sinal em sub-bandas de frequência via Transformada Wavelet Discreta e usa mecanismos de autoatenção para ponderar as sub-bandas mais informativas para o diagnóstico, seguida de módulos Transformer que refinam essa representação no domínio do tempo. O método é validado nos datasets de vibração CWRU e SEU (não em áudio), e serve a este projeto em duas frentes: primeiro, como ponto de comparação metodológico ao MFCC, já que a Transformada Wavelet Discreta é outra família de extratores baseados em decomposição em frequência, mas com resolução tempo-frequência variável (multirresolução) em vez de janelas fixas, o que a torna mais custosa de implementar embarcada; segundo, o próprio resultado de que a informação diagnosticamente relevante se concentra em sub-bandas de frequência específicas e identificáveis reforça, do ponto de vista conceitual, a viabilidade de decimar o sinal (Seção 3), pois descartar o conteúdo de alta frequência fora dessas sub-bandas não compromete a assinatura da falha.

Luo et al. (2024) apresentam o trabalho metodologicamente mais próximo do que esta proposta pretende realizar: um pipeline fim a fim de captura por microfone, pré-processamento (janelamento de Hanning, FFT), extração de coeficientes MFCC e classificação por uma rede convolucional pequena (duas camadas convolucionais, duas de *pooling* e duas densas), distinguindo motores normais de motores em falha. Os autores comparam diretamente MFCC contra STFT como extrator de características e reportam acurácia de validação de 90,83% contra 75,17%, respectivamente, resultado que orienta a escolha

de MFCC como extrator de características também neste projeto. O conjunto de dados utilizado pelos autores, no entanto, é próprio e não foi publicado.

Carrera et al. (2022) classificam falhas em motores elétricos a partir do ruído emitido durante a operação, com aprendizado profundo. O método converte cada trecho de áudio em espectrograma de Mel e o classifica por meio de um *ensemble* de redes convolucionais pré-treinadas (VGG-16 e ResNet50, por transferência de aprendizado a partir do ImageNet), seguidas de um classificador denso totalmente conectado. O problema é tratado como classificação binária (operação normal ou anômala), e não como identificação do tipo específico de falha. Os autores utilizam o dataset ToyADMOS (Koizumi et al., 2019), que registra sons reais de motores elétricos de brinquedos motorizados coletados com quatro microfones a 48 kHz, do qual extraem um subconjunto de 45.300 áudios; para corrigir o forte desbalanceamento entre as classes normal e anômala, recorrem a técnicas de aumento de dados por estiramento temporal e deslocamento de janela. O *ensemble* atinge 97,84% de acurácia e 99,12% de área sob a curva. Duas contribuições desse trabalho são diretamente aproveitadas nesta proposta: a evidência de que o recorte binário normal/falha é suficiente e bem estabelecido na literatura de diagnóstico acústico, e o uso do aumento de dados como resposta ao problema de conjuntos de áudio pequenos ou desbalanceados.

A escolha do MFCC como extrator de características, por sua vez, não se apoia apenas no resultado de Luo et al. Os coeficientes cepstrais nas frequências de Mel (MFCC) resumem o conteúdo espectral de um trecho de áudio em um vetor compacto de coeficientes: o espectro do sinal é filtrado por um banco de filtros distribuído na escala de Mel, que aproxima a forma como o ouvido humano percebe a frequência, e o resultado é comprimido pela Transformada Discreta do Cosseno. Essa representação é a mais consolidada para classificação de áudio desde sua origem em reconhecimento de fala, e aparece de forma recorrente na literatura de diagnóstico de falhas. Cabe registrar que o método não é a representação de maior acurácia disponível (arquiteturas com espectrogramas e redes profundas, como a de Carrera et al. (2022), tendem a superá-lo nesse quesito), mas o que justifica sua adoção neste projeto é outro critério: entre as alternativas, ela é a de menor dimensionalidade e menor custo computacional (um vetor de poucas dezenas de coeficientes por janela, em vez de uma matriz tempo-frequência completa ou da saída de uma rede convolucional profunda), e é precisamente esse o critério determinante quando a cadeia inteira precisa caber e executar dentro de um microcontrolador com memória e capacidade de processamento limitadas.

Em conjunto, esses trabalhos confirmam a viabilidade técnica da abordagem proposta (áudio como sinal de diagnóstico, MFCC como extrator de características, classificadores leves como decisor) e evidenciam a lacuna que este projeto pretende preencher: a execução completa dessa cadeia em hardware embarcado de baixo custo, com recursos de memória e processamento restritos.

A escolha deste tema se justifica, portanto, em três frentes. Primeiro, sob o ponto de vista de aplicação: diagnóstico acústico de falhas é uma técnica de baixo custo e não invasiva, com relevância industrial direta e crescente atenção na literatura recente. Segundo, sob o ponto de vista pedagógico: o projeto integra diretamente os dois eixos da disciplina: Processamento Digital de Sinais (janelamento, transformada de Fourier, extração de características espectrais) e Programação de Software Básico (implementação em C embarcado, gerência de memória limitada), em um problema único e de resultado tangível. Terceiro, sob o ponto de vista de viabilidade: ao optar por reaproveitar um dataset público de áudio já rotulado em vez de projetar uma cadeia de aquisição ao vivo, elimina-se os riscos e o tempo associados a um front-end analógico (microfone, pré-amplificador, calibração de conversor analógico-digital), concentrando o esforço do projeto exatamente nos tópicos centrais da disciplina: extração de características e implementação embarcada.

3 Metodologia




Figura 1: Divisão entre a fase de treino, feita em software, e a fase de inferência, executada embarcada a partir de áudio já gravado na memória do hardware. O computador recebe o resultado por porta serial e atua apenas como painel de exibição.

3.1 Solução Proposta

A solução está organizada em duas fases, ilustradas na Figura 1: uma fase de *treino*, executada em computador, e uma fase de *inferência*, executada inteiramente embarcada.

Essa separação é o que permite dispensar qualquer front-end analógico de captura: o hardware embarcado nunca captura som ao vivo, apenas lê, de sua própria memória não volátil, clipes de áudio já convertidos para PCM.

Conjunto de dados. Será utilizado o subconjunto acústico do dataset de Jung et al. (2023), disponível no Mendeley Data (DOI 10.17632/ztmf3m7h5x.6, licença aberta), composto por cinco arquivos de 60 segundos cada (classes: normal, falha de pista interna de 0,3 mm e 1,0 mm, falha de pista externa de 0,3 mm e 1,0 mm), amostrados a 51,2 kHz. Para a meta de classificação binária, os quatro registros de falha são agrupados em uma única classe; os rótulos originais permanecem disponíveis para a extensão multiclasse. As frequências características de falha calculadas pelos próprios autores (BPFI $\approx$ 272 Hz, BPFO $\approx$ 179 Hz, rotação do eixo $\approx$ 50 Hz) situam-se bem abaixo de 8 kHz, o que permite decimar o sinal para algo entre 8 e 16 kHz sem perda da assinatura da falha, reduzindo substancialmente o espaço de memória necessário no hardware embarcado, um fator decisivo diante do volume pequeno de dados (cerca de cinco minutos de áudio ao todo) e da memória limitada do hardware disponível. A lista completa dos arquivos utilizados está na Seção 5.

Pré-processamento e extração de características. Cada clipe é dividido em janelas (janela de Hanning), sobre as quais se aplica a Transformada Rápida de Fourier e, em seguida, o banco de filtros de Mel e a Transformada Discreta do Cosseno, obtendo os coeficientes MFCC. Como discutido na Seção 2, essa escolha combina a consolidação do MFCC na literatura de diagnóstico de falhas com seu baixo custo computacional e sua representação compacta, requisito imposto pela execução embarcada. Dado o volume reduzido de áudio disponível, o conjunto de treino será ampliado por técnicas de aumento de dados (estiramento e compressão temporal, deslocamento de janela e adição de ruído sintético), estratégia adotada por Carrera et al. (2022) diante de limitação equivalente.

Classificador e estratégia de classes. O sistema será desenvolvido em duas etapas de complexidade crescente. A meta mínima é a classificação binária: motor em operação normal ou em falha, recorte adotado também por Carrera et al. (2022) e que reduz o risco de o projeto não alcançar uma demonstração embarcada funcional dentro do semestre. A meta estendida é a classificação multiclasse, discriminando o tipo e a severidade da falha, a ser perseguida após a validação da cadeia embarcada.

Hardware embarcado. O microcontrolador STM32F411CEU6 foi definido como plataforma principal do projeto. A escolha se apoia em três fatores: o dispositivo já está em posse do grupo, dispensando aquisição; seu núcleo Arm Cortex-M4F dispõe de unidade de ponto flutuante nativa, o que aproxima a implementação embarcada do protótipo desenvolvido em Python e simplifica o porte das operações de logaritmo e da Transformada Discreta do Cosseno envolvidas no cálculo do MFCC; e a plataforma conta com a biblioteca CMSIS-DSP e com a ferramenta X-CUBE-AI, que oferece caminho estabelecido para embarcar o classificador treinado. Permanecem registradas como alternativas o kit

TMS320C5502 eZdsp e o módulo ESP32. O comparativo técnico entre as três plataformas está na Seção 5.

Interface de saída. O diagnóstico será apresentado em dois níveis. No próprio hardware, LEDs indicam de imediato a condição detectada (verde para operação normal, vermelho para falha), cumprindo o papel de sinalização local e autônoma. Em paralelo, o microcontrolador transmite o resultado da inferência por porta serial a um computador, onde uma interface gráfica simples exibe o diagnóstico detalhado: classe reconhecida e grau de confiança.

3.2 Avaliação da Solução

A solução será avaliada em duas frentes. Primeiro, **acurácia de classificação**: o classificador treinado será avaliado sobre uma partição de teste estritamente separada do dataset, com matriz de confusão, tanto na versão executada em software (Python) quanto na versão portada para o hardware embarcado, a comparação entre as duas permite isolar eventuais perdas introduzidas pela portabilidade (quantização, aritmética de precisão reduzida, truncamento). Segundo, **desempenho embarcado**: tempo de execução da cadeia de processamento digital de sinais e ocupação de memória no hardware escolhido. O critério de aceitação segue a formulação de sistemas de tempo real apresentada por Kuo, Lee e Tian (2013), segundo a qual o tempo de processamento somado ao custo das operações de entrada e saída deve ser inferior ao período de amostragem do sinal.

4 Resultados Esperados

Ao final do semestre, espera-se entregar: (i) um classificador funcional, treinado e validado em software, distinguindo operação normal de operação em falha com o melhor desempenho de classificação possível sobre o conjunto de teste; (ii) esse mesmo classificador executando embarcado no STM32F411CEU6, com inferência completa (extração de MFCC e classificação) realizada dentro do microcontrolador; (iii) a interface de diagnóstico em dois níveis descrita na Seção 3, com sinalização por LEDs no hardware e painel detalhado em computador alimentado por porta serial; (iv) uma caracterização quantitativa de tempo de execução e memória ocupada pela cadeia embarcada. Como resultado adicional, caso o cronograma permita após a validação da cadeia embarcada, espera-se estender o classificador à discriminação do tipo e da severidade da falha, reaproveitando integralmente a cadeia de processamento já portada.

5 Infraestrutura Necessária

Hardware. Plataforma principal: placa com microcontrolador STM32F411CEU6, já em posse do grupo. Alternativas registradas: kit de desenvolvimento TMS320C5502 eZdsp e módulo ESP32. Compõem ainda a montagem dos LEDs de sinalização local, com seus resistores, e o cabo de comunicação serial entre o microcontrolador e o computador. O comparativo técnico entre as três plataformas está na Tabela 1.

Software. Python 3 com bibliotecas de processamento de sinais e aprendizado de máquina (NumPy, SciPy, scikit-learn ou PyTorch) para a prototipagem em software e para a interface de diagnóstico em computador, que receberá os resultados por porta serial; ambiente de desenvolvimento STM32CubeIDE com X-CUBE-AI para a plataforma principal; ferramenta de controle de versão (GitHub) para o código do projeto.

Dados. Subconjunto acústico do dataset de Jung et al. (2023), de acesso aberto no Mendeley Data, sem custo e sem necessidade de solicitação de acesso. Os arquivos especificamente utilizados são: ONm_Normal.mat, ONm_BPFI_03.mat, ONm_BPFI_10.mat, ONm_BPFO_03.mat e ONm_BPFO_10.mat (DOI 10.17632/ztmf3m7h5x.6).

Infraestrutura computacional. Notebooks pessoais são suficientes para a etapa de treinamento em software, dado o volume reduzido de dados, e para hospedar a interface de diagnóstico durante a demonstração.

Tabela 1: Comparativo entre a plataforma principal e as alternativas registradas.

Critério	STM32F411CEU6 (principal)	Kit TMS320C5502 eZdsp (alternativa)	ESP32 (alternativa)
Núcleo / clock	Arm Cortex-M4F, até 100 MHz (125 DMIPS)	DSP TMS320C55x, ponto fixo, até 300 MHz (600 MMACS)	Xtensa LX6 dual-core, até 240 MHz (típico)
Memória	512 KB flash, 128 KB RAM (datasheet)	1 MB SDRAM + 512 KB flash SPI no kit; 32 KB ROM interna	~520 KB SRAM, até 4 MB flash externa (varia com o módulo)
Aritmética	Ponto flutuante nativo (FPU), próximo do protótipo em Python	Ponto fixo (Q15/Q31), exige adaptação do MFCC	Ponto flutuante de precisão simples

Continued on next page

Tabela 1: Comparativo entre a plataforma principal e as alternativas registradas. (Continued)

Critério	STM32F411CEU6 (principal)	Kit TMS320C5502 eZdsp (alternativa)	ESP32 (alternativa)
Aceleração de DSP	Instruções DSP do Cortex-M4 + CMSIS-DSP	Motor MAC dedicado do núcleo C55x + DSPLIB (TI)	Biblioteca ESP-DSP
Inferência embarcada	X-CUBE-AI	Sem ecossistema pronto; forward pass implementado manualmente	TFLite Micro / ESP-DL
Disponibilidade	Já em posse do grupo	Disponível no laboratório	Necessita aquisição

6 Metas Físicas

- Proposta de trabalho redigida, apresentada e aprovada.
- Subconjunto acústico preparado e convertido para vetores PCM adequados ao armazenamento em memória embarcada.
- Pipeline de pré-processamento e extração de coeficientes MFCC funcionando em Python, com aumento de dados implementado.
- Classificador binário treinado e validado em software, atingindo boa taxa acurácia sobre a partição de teste.
- Cadeia de processamento digital de sinais portada para o STM32F411CEU6, com a primeira inferência executando dentro do microcontrolador.
- Sistema embarcado validado sobre o conjunto de teste, com matriz de confusão levantada.
- Interface de diagnóstico operante nos dois níveis: sinalização por LEDs no hardware e painel detalhado em computador via porta serial.
- Demonstração física funcionando e relatório final entregue.

7 Cronograma de Atividades

Período	Atividade
08–14/09	Definição final de escopo, dataset e hardware; redação e apresentação da proposta de trabalho
15–21/09	Download e preparação do subconjunto acústico; conversão dos arquivos <code>.mat</code> para vetores PCM
22–28/09	Implementação, em Python, do pipeline de pré-processamento, do aumento de dados e da extração de coeficientes MFCC
29/09–05/10	Treinamento e validação do classificador binário em software; redação do 1º relatório parcial
06–12/10	Configuração do ambiente de desenvolvimento embarcado (STM32CubeIDE e X-CUBE-AI)
13–19/10	Porte da cadeia de processamento digital de sinais para C, no STM32F411CEU6
20–26/10	Primeira inferência on-device funcionando; redação do 2º relatório parcial
27/10–09/11	Validação do sistema embarcado sobre o conjunto de teste; construção da matriz de confusão
10–16/11	Testes de validação complementares e caracterização de desempenho embarcado (tempo de execução e memória)
17–23/11	Implementação da interface de diagnóstico (sinalização por LED e painel serial no computador); ensaio da apresentação final
24–30/11	Ajustes finais, redação e entrega do relatório final; apresentação final

8 Orçamento

Item	Já disponível?	Custo estimado
Placa STM32F411CEU6 (plataforma)	Sim (grupo)	R\$ 0,00
Dataset acústico (Jung et al., 2023)	Sim (acesso aberto)	R\$ 0,00
Kit TMS320C5502 eZdsp (alternativa)	Sim (laboratório)	R\$ 0,00
LEDs (vermelho/verde) e componentes	Parcial	R\$ 0 a 20
Módulo ESP32 (alternativa)	Não	R\$ 40 a 70
Total estimado		R\$ 0 a 90

9 Riscos Potenciais

Restrições de Memória do Hardware: Há um risco de impacto alto, com probabilidade média, de que a memória do hardware embarcado seja insuficiente para armazenar os cliques de áudio e o modelo de machine learning. Para mitigar esse problema, as capacidades exatas de RAM e flash serão confirmadas antes da Fase 2. Caso necessário, o áudio será decimado para taxas entre 8 e 16 kHz e um classificador mais raso será adotado.

Sobreajuste do Classificador: Devido ao volume reduzido de áudio disponível, existe uma probabilidade média de sobreajuste, o que geraria um grande impacto ao projeto. A estratégia de mitigação envolve aplicar técnicas de aumento de dados (conforme Carrera et al., 2022) e manter a partição de teste estritamente separada. Além disso, o recorte binário estabelecido como meta mínima já oferece menor suscetibilidade ao sobreajuste do que a discriminação multiclasse.

Acurácia Insuficiente: Embora a probabilidade seja baixa, o impacto de o classificador embarcado apresentar acurácia sensivelmente inferior à obtida na versão em software é considerado alto. A contenção desse risco será feita ajustando iterativamente o número de coeficientes MFCC e a arquitetura do modelo, utilizando o benchmark de Luo et al. (2024) como base comparativa.

Desafios no Porte das Operações Matemáticas: A transposição das operações de logaritmo e DCT para o hardware apresenta probabilidade baixa e impacto médio. A mitigação baseia-se no uso do ponto flutuante nativo e da biblioteca CMSIS-DSP do microcontrolador STM32F411CEU6, que reduzem significativamente a complexidade em

comparação com alternativas de ponto fixo. Cada bloco da cadeia de processamento será validado isoladamente contra a referência implementada em Python.

Atrasos na Integração Hardware/Software: Dificuldades na integração podem gerar atrasos no cronograma. Para evitar que isso afete a entrega final, as orientações programadas para as semanas de 09/11 e 16/11 servirão como pontos de verificação antecipada. Adicionalmente, o bloco de desenvolvimento alocado entre 27/10 e 09/11 já embute uma folga estratégica de duas semanas dedicada a possíveis reprogramações.

10 Metodologia de Gerenciamento

O gerenciamento do projeto será aplicado sobre as frentes de trabalho seguindo três pilares práticos:

- **Organização:** Manutenção de um espaço centralizado para acompanhamento do cronograma, metas físicas, materiais de referência e quadro de tarefas com prazos e responsáveis definidos.
- **Padronização:** Versionamento de código em repositório compartilhado no GitHub e elaboração da documentação colaborativa simultânea via Overleaf. Regras de nomenclatura e estrutura de diretórios serão fixadas desde a primeira fase.
- **Controle:** Avaliação semanal do progresso aproveitando as sessões de orientação. O avanço será contrastado com as metas estabelecidas e o cronograma previsto, garantindo o replanejamento imediato e redistribuição de tarefas caso ocorram desvios.

11 Bibliografia

Referências

- [1] JUNG, W.; KIM, S.-H.; YUN, S.-H.; BAE, J.; PARK, Y.-H. *Vibration, acoustic, temperature, and motor current dataset of rotating machine under varying operating conditions for fault diagnosis*. Data in Brief, v. 48, 109049, 2023. DOI: 10.1016/j.dib.2023.109049.
- [2] TIAN, A.; ZHANG, Y.; MA, C.; CHEN, H.; SHENG, W.; ZHOU, S. *Noise-robust machinery fault diagnosis based on self-attention mechanism in wavelet domain*. Measurement, v. 207, 112327, 2023. DOI: 10.1016/j.measurement.2022.112327.

- [3] LUO, D.; QUAN, Y.; XUE, W.; LIN, F. *Motor fault detection based on sound signal*. In: 2024 The 6th International Conference on Telecommunications and Communication Engineering (ICTCE), Chengdu, China. New York: ACM, 2024. p. 83–88. DOI: 10.1145/3705391.3705405.
- [4] CARRERA, J. D.; MATUTE, P. V.; PELÁEZ, E.; LOAYZA, F. R. *Fault diagnosing for electric motors based in noise data classification using deep learning*. In: 2022 IEEE ANDESCON, Barranquilla, Colombia, 2022. p. 1–6. DOI: 10.1109/ANDESCON56260.2022.9989522.
- [5] KOIZUMI, Y.; SAITO, S.; UEMATSU, H.; HARADA, N.; IMOTO, K. *ToyADMOS: a dataset of miniature-machine operating sounds for anomalous sound detection*. In: IEEE Workshop on Applications of Signal Processing to Audio and Acoustics (WASPAA), 2019. Dataset disponível em: <https://zenodo.org/records/3351307>.
- [6] KUO, S. M.; LEE, B. H.; TIAN, W. *Real-Time Digital Signal Processing: Fundamentals, Implementations and Applications*. 3. ed. Chichester: John Wiley & Sons, 2013.